

1 commit · 68 fichiers · base origin/swift

Anatomie du prompt global

CHANTIER A · SLIDES 2 → 5

Comprendre et réorganiser le prompt

CHANTIER B · SLIDES 6 → 7

Un prompt global et des instructions globales

≈ -81 %

DE TOKENS ENVOYÉS AU MODÈLE
votre agent de test, 24 outils

55 → 10

PAGES RELUES PAR RÉPONSE
votre agent de test, 24 outils

0

RÈGLE CACHÉE PAR AGENT
garde-fous supprimés : tout est dans son texte

+37

TESTS


CODE COULEUR EMPLOYÉ SUR LES 7 SLIDES — UNE TEINTE = UNE FAMILLE DE BLOCS DU PROMPT

 **Plateforme** — identique pour tout agent, tout tour  **Consignes Mermaid** — la règle commune à tous : le format des schémas  **Outils** — annuaire et mode d'emploi
 **Agent** — le métier propre à cet agent  **Conversation** — ce qui vient de l'utilisateur

Le prompt système complet : ordre et contenu

Un prompt se lit de gauche à droite. **Deux blocs plateforme apparaissent en tête, deux blocs disparaissent, le bloc de l'agent descend.** Ce que contient chacun est détaillé en dessous.

AVANT – ORDRE HISTORIQUE



- Prompt global** · écrit par l'admin plateforme
Le ton et les standards attendus de tous les agents du déploiement.
- Instructions globales** · livrées avec le produit
N'appeler que les outils fournis, ne jamais en simuler un, dire quand on ignore.
- Garde-fous** · supprimés par cette branche
Règles déclarées à part, invisibles de l'opérateur. Supprimées : le texte de l'agent fait foi.
- Consignes Mermaid** · livrées avec le produit
Comment écrire un schéma Mermaid lisible par l'interface. Deux fois plus court.

- Outils** · dressé au démarrage de l'agent
Les outils qu'il peut appeler, groupés par serveur, chacun résumé en une ligne.
- Mode d'emploi des serveurs** · écrit par qui configure le serveur
L'ordre d'appel des outils d'un serveur et ses interdits. Fait partie du bloc outils.
- Agent** · écrit par l'auteur de l'agent
Son métier et ses propres règles : ce qu'il fait, pour qui, ce qu'il s'interdit.
- Contexte et fichiers** · apportés par l'utilisateur
Les consignes choisies pour cette conversation et les fichiers qui y sont joints.

LÉGENDE DU SCHÉMA – LE CODE COULEUR COMPLET EST EN SLIDE 01

--- bloc déplacé ■ bloc supprimé, contenu déjà présent ailleurs ■ bloc nouveau (chantier B) Largeurs schématiques.


Deux agents différents : à partir d'où leurs prompts diffèrent-ils ?

Le cache d'un fournisseur de modèle s'arrête au **premier caractère qui diffère**. Ouvrir sur le bloc de l'agent le rendait inutilisable ; ouvrir sur la plateforme repousse la divergence très loin.

AVANT — ORDRE HISTORIQUE



APRÈS — ORDRE DE CETTE BRANCHE



LÉGENDE DU SCHÉMA — CHAQUE RUBAN EST UN PROMPT SYSTÈME ENTIER

--- premier caractère qui diffère — portion réutilisable par le cache

Largeurs schématiques : le bloc outils varie avec les serveurs de l'agent. **Second effet** : le bloc de l'agent est désormais le plus proche de sa réponse.

Un seul bloc du prompt : la présentation des outils

On ne regarde ici **qu'une partie du prompt système** — le bloc « outils » de la slide 02. Les autres blocs ne changent pas.

LE PROMPT SYSTÈME COMPLET (SLIDE 02)



c'est ce bloc, et lui seul, qui change

AVANT

Une liste plate, sans regroupement

nom de l'outil	sa fiche technique entière
nom de l'outil	sa fiche technique entière
nom de l'outil	sa fiche technique entière

fiche technique = à quoi sert l'outil, ses arguments, le format de sa réponse et ses codes d'erreur — copiés en entier, outil par outil
... et ainsi de suite pour les 57 outils, les uns derrière les autres

règles génériques d'appel d'outils

supprimées — elles répétaient ce qui est déjà dit ailleurs

mode d'emploi du serveur

livré séparément, tout à la fin du prompt,
et recollé à chaque appel au modèle

xN

APRÈS

Un annuaire, regroupé par serveur

titre du serveur : recherche documentaire

nom de l'outil résumé d'une ligne

nom de l'outil résumé d'une ligne

mode d'emploi de ce serveur, juste sous ses outils

titre du serveur : action tabulaire

nom de l'outil résumé d'une ligne

mode d'emploi de ce serveur, juste sous ses outils

autres outils

nom de l'outil résumé d'une ligne

la fiche technique complète continue de partir au modèle, mais par un canal technique séparé — elle n'est plus recopiée dans le texte


« autres outils » : ceux fournis par Fred lui-même, jusqu'ici absents de cet annuaire alors que le modèle pouvait déjà les appeler

LÉGENDE DU SCHÉMA — LE CODE COULEUR COMPLET EST EN SLIDE 01

fiche technique complète d'un outil résumé d'une ligne mode d'emploi du serveur supprimé livré hors du prompt statique

Tout ce qu'un agent relit avant de vous répondre

Un agent ne se souvient de rien : à **chaque** question, on lui renvoie l'intégralité de son mode d'emploi, puis la conversation. Ici, votre agent de test : 24 outils en trois familles, mesuré sur la plateforme.



le trait rouge ne contient rien : il marque la fin de ce que la plateforme envoie. À sa droite commence la conversation, qui n'a pas changé.

LES SIX POSTES DE CE QUE LE MODÈLE REÇOIT

- Outils documents (3) — tout ce que le modèle reçoit sur eux
- Outils fichiers (16) — tout ce que le modèle reçoit sur eux
- Outils tabulaires (5), mode d'emploi du serveur compris
- Consignes Mermaid — et, avant, les consignes répétées d'appel d'outils
- Ce qui est propre à cet agent — son rôle, sa façon de répondre
- Les deux nouveaux blocs plateforme

Total envoyé au modèle

AVANT	APRÈS	
763	836	désormais listés dans le texte, une ligne chacun
10 205	474	fiches complètes en double avant ; résumées, une seule fois
10 756	1 744	idem ; le mode d'emploi (890) est inchangé
1 550	783	deux fois plus courtes, rien de perdu
437	437	intact — c'est son métier
—	+ 168	ajouté par le chantier B, pour tous les agents
23 711	4 442	≈ – 81 %

LÉGENDE – AGENT DE TEST, 24 OUTILS · UNE PAGE ≈ 430 TOKENS

fin de ce que la plateforme envoie — délimiteur, sans contenu

Un **token** ≈ un mot court ou un morceau de mot. Conversation (≈ 500 tokens) non comptée.


Impact environnemental — un token retiré l'est de chaque appel, pour chaque utilisateur, indéfiniment. Moins de tokens, c'est moins de calcul GPU, donc moins d'électricité et d'eau de refroidissement.

COÛT · MISTRAL SMALL 4 · 1 000 CONVERSATIONS

	AVANT	APRÈS
Entrée (prompt + 1 question)	3,56 \$	0,67 \$
Sortie (1 réponse ≈ 300 tokens)	0,18 \$	0,18 \$
Total	3,74 \$	0,85 \$ ÷ 4,4

Deux nouveaux blocs en tête : l'un s'écrit, l'autre est livré

Un admin peut réécrire entièrement le premier — jusqu'à le vider. La discipline dont dépend la cohérence de tous les agents ne doit pas partir avec : elle vit dans le second, livré et verrouillé.



LÉGENDE DU SCHÉMA — LE CODE COULEUR COMPLET EST EN SLIDE 01

ÉDITABLE

écrit et remplaçable par un admin

LECTURE SEULE

livré avec le produit, aucune écriture possible

■ blocs suivants, atténués — voir slide 02

Et si personne n'écrit rien dans l'admin ?

Un prompt global de départ est **toujours livré avec le produit**. La question n'est jamais « y a-t-il un prompt global ? » mais « est-ce celui livré, celui de l'admin, ou aucun ? »

D'OÙ VIENT LE PROMPT GLOBAL, À CHAQUE QUESTION



Personne d'autre ne peut y toucher : ni un utilisateur dans la conversation, ni une application qui appelle l'agent.
Ce texte ne vient que de l'écran d'administration — c'est ce qui garantit qu'il s'applique à tous les agents, pour tout le monde.

CE QU'UN ADMIN A FAIT

Personne n'a encore rien écrit

aucune ligne en base — cas d'un déploiement neuf

Un admin a écrit et enregistré

une ligne en base contient son texte

Un admin a tout effacé, puis enregistré

la ligne existe, mais elle est vide

PROMPT GLOBAL LIVRÉ AVEC LE PRODUIT

✓ **utilisé**

c'est lui qui s'applique


✗ **remplacé**

celui de l'admin prend sa place

✗ **pas remis**

effacer est un choix, pas un oubli

TÊTE DU PROMPT OBTENUE



les instructions globales, elles, sont là dans les trois cas — personne ne peut les retirer

LÉGENDE DU SCHÉMA — LE CODE COULEUR COMPLET EST EN SLIDE 01

prompt global livré — texte de départ embarqué dans le produit

prompt global de l'admin — enregistré dans l'écran d'admin, remplace le texte livré

aucun prompt global — champ vidé puis enregistré ; le texte livré n'est pas remis

chemin suivi par le texte, à chaque question